

Avaliação ML — Árvore de Decisão

Disciplina: Introdução ao Aprendizado de Máquina

Turma: 8 alunos

Dataset: Bank Marketing (UCI)

Docente: Prof. Helder



Cronograma

Data	Evento	O quê
22/06 (segunda-feira)	Início	Recebem este guia + notebook de referência (vazio)
25/06 (quinta-feira)	● 1ª Apresentação	Checkpoint: EDA + modelo
02/07 (quinta-feira)	● Entrega final	Notebook completo + apresentação final (10 min/aluno)



O que entregar (resumo executivo)

● Checkpoint — 25/06

Cada aluno apresenta (2-6 min, preferencialmente gravar um video e exibir em sala):

- ✓ Dataset carregado e explorado (descrever as variáveis principais)
- ✓ Pré-processamento: tratamento de "unknown", células vazias, duplicatas, outliers
- ✓ **Árvore de Decisão funcionando** com matriz de confusão

Objetivo: verificar se está no caminho certo; professor tira dúvidas técnicas.

Nota: Se gravar o vídeo, não precisa apresentar imagens e audio pessoais. Se preferir, pode até mesmo usar um "avatar".

● Entrega Final — 02/07

Arquivo único: `[SOBRENOME_NOME]_avaliacaoML_2026_1.ipynb`

Estrutura mínima esperada:

1. Introdução
 - Contexto do problema (prever adesão bancária)
2. Carga e EDA
 - Dataset carregado (shape)
 - Distribuição do alvo
 - "unknown" por coluna
 - Outliers identificados
3. Pré-processamento
 - Remoção de duplicatas
 - Remoção de `duration` (data leakage)
 - Identificação de outliers
 - Split treino/teste (75/25)
4. Modelo: Árvore de Decisão
 - Treino com $\text{max_depth} \leq 5$
 - Métricas
 - Matriz de confusão
 - Visualização da árvore
5. Interpretação
 - Quais variáveis a árvore usa para decidir?
6. Análise de sensibilidade a:
 - Outliers
 - Desbalanceamento

Esperado: células de markdown, código e representação gráfica, bem document

| Programação rápida (sugestão)

22 a 24/06: EDA, limpeza e treinar árvore

25/06: Checkpoint

Mostre EDA, outliers encontrados, árvore treinada com métricas. Tire dúvidas técnicas.

25/06 a 01/07: Polir, visualizar

Visualize a árvore (`plot_tree`), calcule importância das variáveis, escreva interpretação, verifique o notebook de referência para boas práticas.

02/07: Entrega e apresentação

Entregue notebook, apresente 10 min resumindo: problema → EDA → modelo → resultados → conclusão

Imports essenciais>

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.model_selection import train_test_split
from sklearn.metrics import (classification_report, confusion_matrix,
                             ConfusionMatrixDisplay, roc_auc_score)
```

Armadilhas comuns (evite!)

1. **Usar `duration` no modelo** → data leakage! (só existe depois da ligação)
2. **Esquecer `class_weight="balanced"`** → modelo prevê sempre "no" (está desbalanceado!)
3. **Não fazer split treino/teste** → resultado ilusório (data leak interno)
4. **Reportar só acurácia** → dataset desbalanceado, use F1 também
5. **Árvore muito profunda** → overfitting (use `max_depth ≤ 5`)
6. **Árvore muito rasa** → underfitting (use `max_depth ≥ 3`)

Dúvidas?

Serão tratadas durante a atividade de Checkpoint.

Sucesso no trabalho!